

Tối ưu hóa truy xuất trong hệ thống RAG thông qua kỹ thuật bổ sung ngữ cảnh chủ động và làm phẳng dữ liệu bán cấu trúc

Hội thảo khoa học Quốc gia về CNTT và Truyền thông (ICT) – Đồng Tháp

Ngô Nguyễn Tường Nghi, Lê Thị Bích Hằng, Nguyễn Đình Hưng

Trường Đại học Nha Trang
{nghiinnt, hangltb, hungnd}@ntu.edu.vn

22 tháng 5, 2026

Nội dung báo cáo

- 1 Giới thiệu
- 2 Tổng quan nghiên cứu
- 3 Phương pháp đề xuất
- 4 Thực nghiệm
- 5 Kết quả và thảo luận
- 6 Kết luận

- **LLMs (GPT-4, Claude):** Mạnh mẽ nhưng gặp giới hạn về tri thức tĩnh và lỗi “ảo giác” (hallucination).
- **Giải pháp RAG:** Truy xuất tri thức ngoại vi để bổ sung bối cảnh cho mô hình tạo sinh.
- **Thách thức:** Hiệu suất phụ thuộc vào chất lượng truy xuất (Retrieval).
- **Dữ liệu bán cấu trúc (JSON, Danh sách):** Các thuật toán chia nhỏ (Text Splitter) truyền thống thường phá vỡ cấu trúc logic → **Mất ngữ cảnh (Context Loss)**.


Hạn chế của phân mảnh truyền thống

Phân mảnh cố định/đệ quy


Dựa trên ngưỡng ký tự hoặc token.

- Cắt ngang các khối logic trong JSON.
- Làm đứt gãy mối liên kết cha-con (ví dụ: điểm chuẩn tách rời tên ngành).

Hạn chế của phân mảnh truyền thống: Chunk dữ liệu bị cô lập



Quy trình tiền xử lý dữ liệu



Kỹ thuật 1: Làm phẳng dữ liệu (Data Flattening)

Chuyển đổi các cặp key: value thành các mệnh đề ngôn ngữ tự nhiên.

Dữ liệu JSON thô:

```
{  
  "ma_nganh": "7480101",  
  "ten_nganh": "KH my tnh"  
}
```

→ **Kết quả:**
"Ngành Khoa học máy tính có mã ngành là 7480101."

- Giúp mô hình nhận diện thực thể tốt hơn.
- Tối ưu không gian vector cho tìm kiếm tương đồng.

Kỹ thuật 2: Bổ sung ngữ cảnh chủ động (Context Injection)

Giải pháp

Lắp lại thông tin định danh cốt lõi vào **từng** phân đoạn dữ liệu.

- **Trước:** “Điểm chuẩn là 24.” (Mất ngữ cảnh ngành/năm).
- **Sau:** “[**Trường ĐH Nha Trang, Năm 2026**] Ngành Khoa học máy tính có điểm chuẩn là 24.”

Lợi ích: Mỗi chunk dữ liệu trở nên độc lập về mặt ngữ nghĩa, giúp truy xuất chính xác ngay cả khi câu hỏi của người dùng thiếu từ khóa định danh.

- **Bộ dữ liệu:** Thông tin tuyển sinh NTU 2025-2026 (50 mã ngành).
- **Nền tảng:** AnythingLLM (Docker/Linux).
- **Mô hình:**
 - Embedding: Gemini Embedding 001 (Google).
 - LLM: Llama-3.1-8b-instant.
 - Giám khảo: GPT-4o-mini (LLM-as-a-Judge).
- **Đánh giá:** Framework RAGAS (3 thang đo chính).

Kết quả định lượng (RAGAS)

Thang đo	JSON thô	Markdown	Đề xuất
Context Precision	0.7933	0.7817	0.8556
Faithfulness	0.5484	0.6371	0.7990
Answer Correctness	0.5524	0.6181	0.7017

Bảng: So sánh hiệu năng giữa các kịch bản dữ liệu

- **Context Precision:** Tăng **+6.23%** so với JSON thô.
- **Answer Correctness:** Tăng **+8.36%** so với Markdown.

Thảo luận: Sự đánh đổi (Trade-offs)

- **Chi phí tài nguyên:**

- Tổng số lượng token tăng 18% (do lặp lại ngữ cảnh).
- Độ trễ (latency) tăng nhẹ (120ms).

- **Giá trị mang lại:**

- Bảo toàn tính toàn vẹn của dữ liệu định danh.
- Giảm thiểu ảo giác (Hallucination) đáng kể.
- Phù hợp cho các hệ thống đòi hỏi độ chính xác cao như tư vấn tuyển sinh.

Kết luận và Hướng phát triển

Kết luận:

- Tiền xử lý dữ liệu ở tầng biểu diễn cực kỳ quan trọng cho RAG.
- Kỹ thuật làm phẳng và bổ sung ngữ cảnh chủ động giúp tối ưu hóa truy xuất dữ liệu bán cấu trúc.

Hướng phát triển:

- Thử nghiệm với các mô hình ngôn ngữ nhỏ (Small Models) chạy nội bộ (Local).
- Kết hợp với kỹ thuật *Parent Document Retrieval* (PDR).
- Mở rộng bộ dữ liệu kiểm thử và triển khai thực tế tại NTU.

CẢM ƠN QUÝ HỘI THẢO!

HỎI & ĐÁP